INFO0708 - Ateliers IA (Master 1 IA)

Ce projet regroupe les TPs. Il inclut une interface graphique fait avec **Streamlit** pour naviguer entre les différents tps et moteur de recherche (Word Embeddings, Traitement de texte, Moteur de recherche, etc.).

Requis

- **Python 3.8** ou supérieur installé sur la machine.

Installation

1. Créer un environnement virtuel (Recommandé)

Il est conseillé d'utiliser un environnement virtuel pour isoler les dépendances du projet.

Sur macOS / Linux : `bash python3 -m venv venv source venv/bin/activate`

Sur Windows : `bash python -m venv venv venv\Scripts\activate`

2. Installer les dépendances

Installez les librairies nécessaires répertoriées dans le fichier `requirements.txt` .

```
pip install -r Interfac/requirements.txt
```

(Note : Assurez-vous d'être à la racine du projet pour que le chemin soit correct, ou ajustez-le).

Lancement de l'application

Pour lancer l'interface principale qui regroupe tous les TP :

1. Assurez-vous d'être à la racine du projet (et que votre environnement virtuel est activé).
2. Exécutez la commande suivante :

```
streamlit run Interfac/Accueil.py
```

Votre navigateur par défaut devrait s'ouvrir automatiquement à l'adresse `http://localhost:8501`.

Contenu

TP1 : Traitement de texte et Regex

Introduction aux manipulations de chaînes de caractères et utilisation des expressions régulières pour le nettoyage de texte.

Fonctionnalités explorées : * Exploration de l'arborescence du corpus (structure, liste fichiers, dossiers). * Calcul de statistiques : nombre de documents, répartition par langue (FR/EN), comptage des étudiants. * Vérifications de cohérence : extensions de fichiers (.txt), correspondance des paires de documents.

Paramètres modifiables : * `Chemin du corpus` : Dossier racine contenant les textes à analyser (par défaut "Textes").

Rapport Complet

Générer Statistiques Structurelles

Exécution de `statistiques_structure`...

Rapport Console

```
Il y a 4 sous-corpus :
['UFR', 'Univ_Nationale', 'IUT', 'Univ_Etrangere']
44
Nombre de documents en français : 21
Nombre de documents en anglais : 21
Nombre estimé d'étudiants : 21
Correspondance des langues : OK
tout les fichiers sont bons

--- Rapport de structure du corpus ---
Nombre de sous-corpus : 4 (UFR, Univ_Nationale, IUT, Univ_Etrangere)
Nombre total de fichiers : 44
Fichiers français : 21
Fichiers anglais : 21
Nombre d'étudiants identifiés : 21
Nombre d'anomalies détectées : 0
-----------------------------------
```

TP2 : Corrections et distances

Calcul de distances entre mots (Levenshtein, Jaccard) et implémentation de correcteurs orthographiques.

Fonctionnalités explorées : * Standardisation de texte : conversion en minuscules, suppression de balises HTML/XML, normalisation Unicode. * Gestion des accents : correction automatique et uniformisation. * Traitement de la ponctuation : suppression contextuelle, espacement, normalisation. * Détection de langue : basée sur le contenu ou le nom du fichier.

Paramètres modifiables : * **Entrée** : Saisie directe de texte ou chargement d'un fichier `.txt` . * **Options** : Activation de la correction d'erreurs ou l'uniformisation des accents. Choix des caractères de ponctuation à conserver.

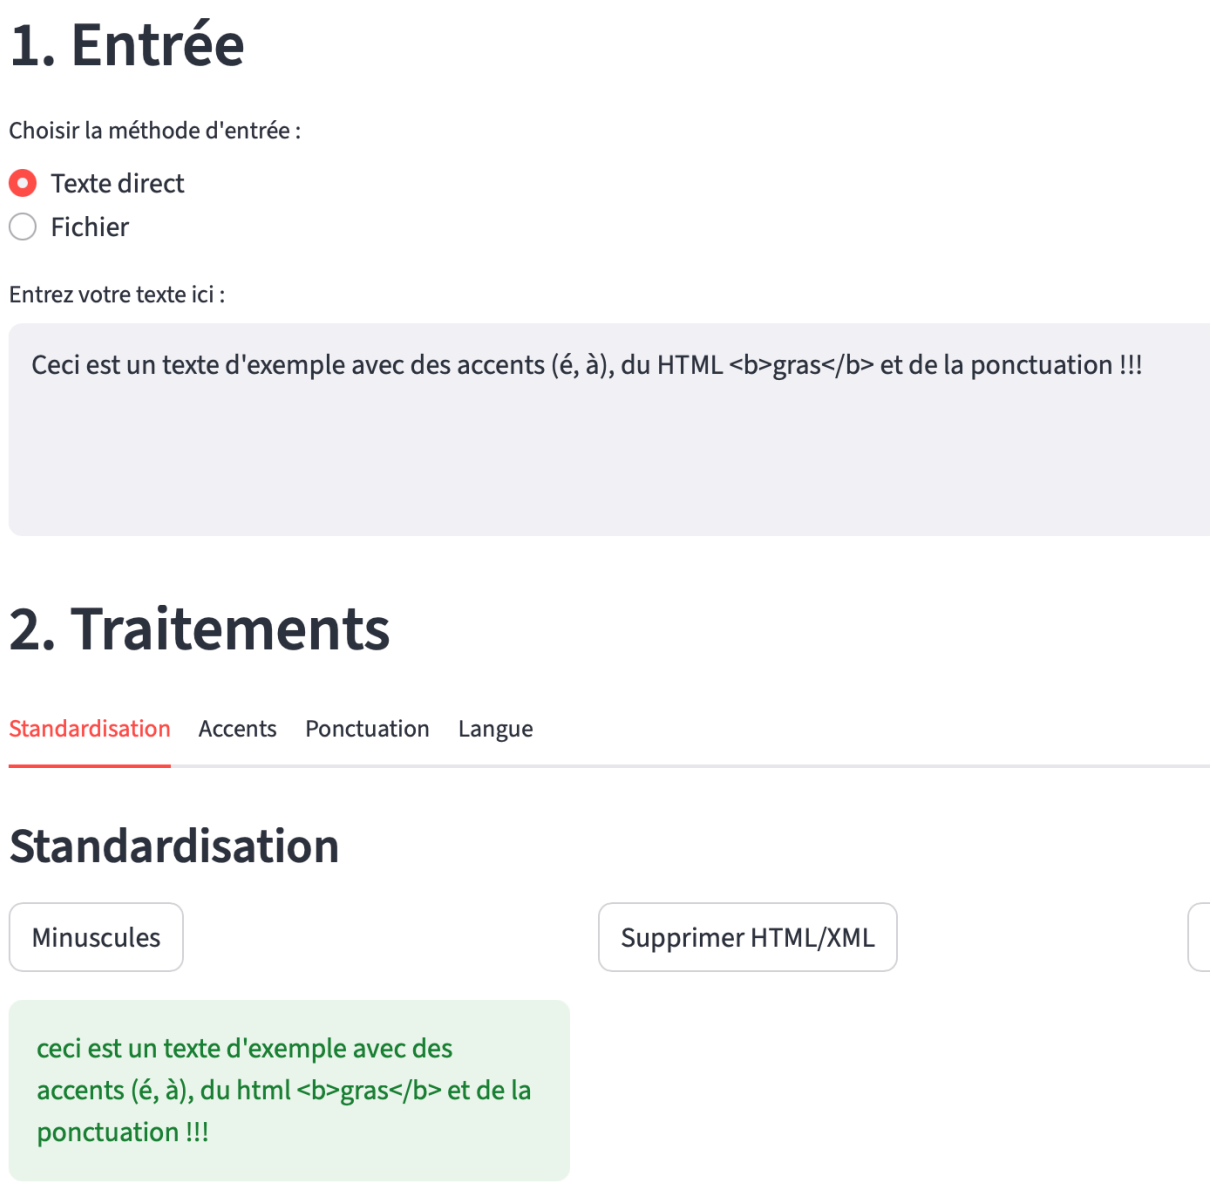

TP3 : Modèles N-grammes

Création et utilisation de modèles de langage basés sur les N-grammes pour la prédiction de texte.

Fonctionnalités explorées : * Segmentation en phrases et tokenisation (gestion dates, décimaux, sigles). * Génération de N-grammes (unigrammes, bigrammes...) au niveau phrase ou document. * Analyse statistique (Loi de Zipf, Happax) et pipelines de prétraitement (Stemming, Lemmatisation).

Paramètres modifiables : * **Langue** : Français ou Anglais. * **Segmentation** : Activation de la détection de dates, numéros et sigles. * **N-grammes** : Taille N (slider), niveau d'analyse (document vs phrase). * **Filtres** : Longueur minimale des mots, seuil d'occurrences, stop-words.

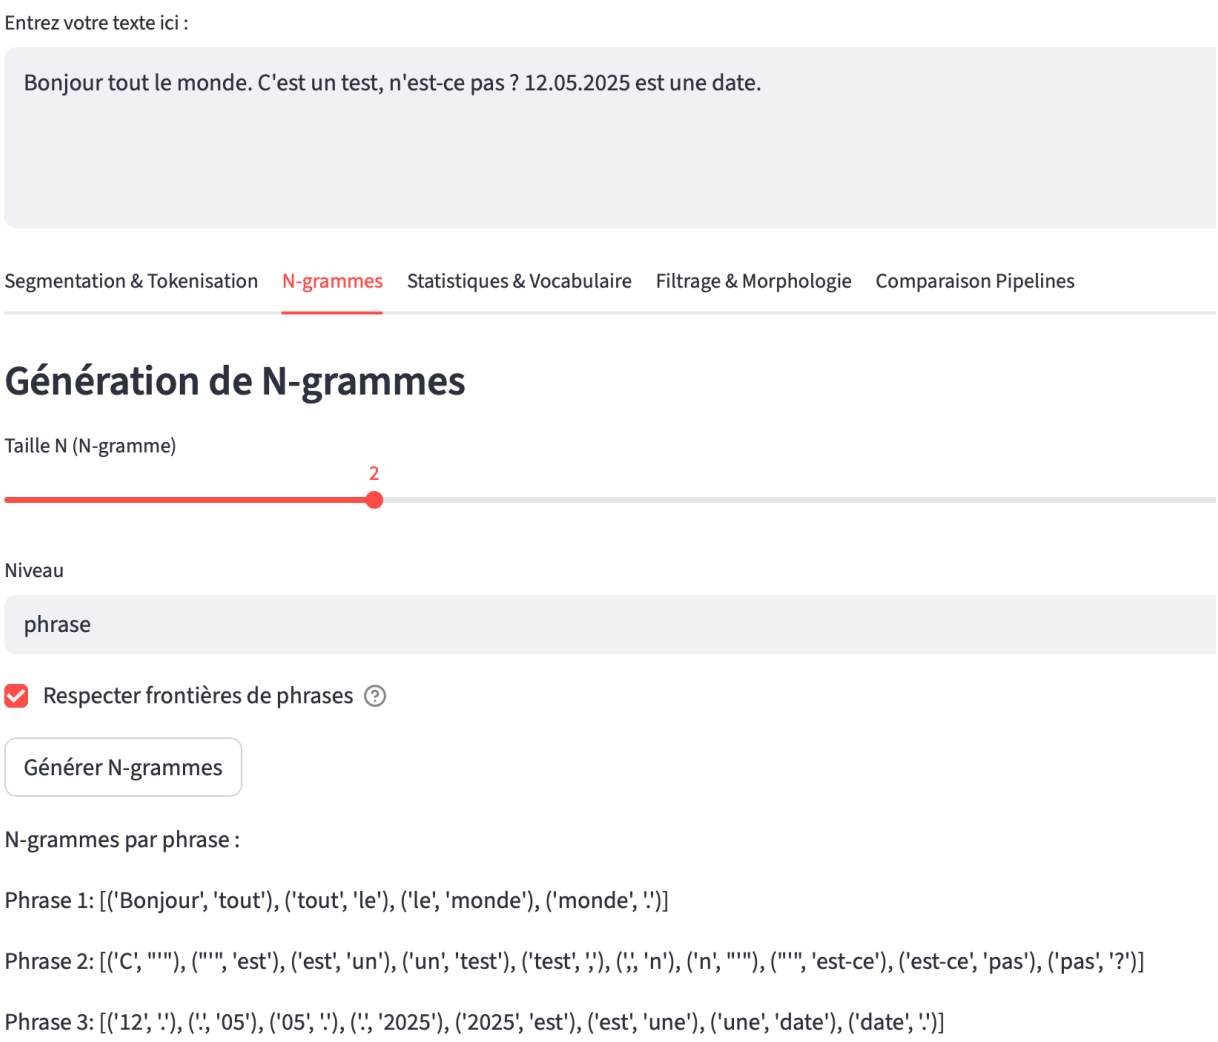

TP4 : Classification de textes

Algorithmes de classification de textes (Naive Bayes, etc.) pour catégoriser des documents. *(Note: L'interface se concentre ici sur les techniques de vectorisation préparatoires)*

Fonctionnalités explorées : * Démonstration des vectorisations : One-Hot, Bag of Words (BoW), TF-IDF, BM25. * Normalisation de vecteurs (L1, L2, MinMax).

Paramètres modifiables : * **Vocabulaire** : Liste de mots définissant l'espace vectoriel. * **Textes** : Zones de saisie pour tester la transformation texte -> vecteur. * **Hyperparamètres** : Formule IDF pour TF-IDF, paramètres $k1$ et b pour BM25.

TP5 : Extraction d'information

Techniques d'extraction d'entités nommées et d'informations structurées. *(Note: L'interface se concentre ici sur la vectorisation avancée et les distances)*

Fonctionnalités explorées : * Vectorisation avancée : Phrases vs Documents (concaténation ou agrégation). * Calcul de distances et similarités (Euclidienne, Cosinus, manhattan...).

Paramètres modifiables : * **Vocabulaire** : Liste de mots commune. * **Méthodes** : Choix entre TF, BoW, TF-IDF. * **Stratégie** : Agrégation par somme, moyenne ou max pour les documents.

Vectorisation de Phrase

Transforme une liste de mots en un vecteur numérique.

Phrase à vectoriser

le chat dort

Configuration IDF (simulée)

Valeurs IDF (séparées par virgule, même ordre que vocab)

0.5, 0.5, 1.0, 1.0, 1.2, 1.5, 1.5

Méthode

tfidf

Vectoriser Phrase

Vecteur Résultat :

	chat	chien	dort	mange	maison	souris	fromage
0	0.1667	0	0.3333	0	0	0	0

TP6 : Word Embeddings (Word2Vec / FastText)

Exploration des plongements de mots (Word Embeddings) avec Word2Vec et FastText.

Fonctionnalités explorées : * Entraînement de modèles (Word2Vec, FastText). * Exploration sémantique : recherche de voisins proches, analogies, similarité de phrases. * Expansion de requêtes pour la recherche d'information.

Paramètres modifiables : * **Modèle** : Algorithme (Word2Vec vs FastText). * **Hyperparamètres** : Dimension des vecteurs, taille de fenêtre, époques. * **Données** : Choix entre un corpus jouet ou un texte personnalisé.

Voisins les plus proches (Most Similar)

Mot cible

neurones

Chercher Voisins

	Mot	Similarité
0	automatique	0.1991
1	réseaux	0.1702
2	fascinant	0.1459
3	les	0.0642
4	est	-0.0028
5	de	-0.0135
6	apprennent	-0.0236
7	l'apprentissage	-0.0328
8	vite	-0.0523

Calcul de Similarité (Mot à Mot)

Mot 1

l'apprentissage

Mot 2

automatique

Calculer Similarité

TP7 : Moteur de Recherche Vectoriel

Moteur de recherche performant permettant d'indexer et de rechercher dans le corpus de documents textuels.

Fonctionnalités explorées : * Indexation complète d'un corpus de documents. * Recherche vectorielle avec classement par pertinence.

Paramètres modifiables : * **Indexation** : Activation du stemming/stopwords, choix de la granularité (Phrase vs Document) et pondération (TF-IDF/TF/BoW). * **Recherche** : Requête utilisateur, mesure de similarité (Cosinus, Jaccard...), nombre de résultats (Top K).